

Trabajo Práctico Integrador — Módulo R

Maestría en Econometría — Universidad Torcuato Di Tella

Docente: Ian Evangelos Bounos — Año 2026

Modalidad: Grupos desde 1 hasta 3 personas inclusive

Entrega: 21 de Septiembre, 23:59

Formato: Scripts de R (.R) entregados vía GitHub, más un informe en PDF

Consulta: Durante el período de fin de clases habrá una clase de consulta virtual. Se recomienda fuertemente ir mostrando resultados parciales (gráficos exploratorios, primeras estimaciones) durante las clases o en esa consulta, en vez de dejar todo para último momento.

Introducción

Este trabajo práctico integra las herramientas vistas a lo largo del módulo R: manejo de datos con `tidyverse`, visualización con `ggplot2`, y al menos una de las técnicas de modelado vistas en clase (regresión lineal y regularización, series de tiempo, modelos lineales generalizados, o datos de panel).

A diferencia del trabajo del módulo Python, acá el punto de partida no es un dataset dado: la primera tarea del grupo es **elegir un dataset propio**, justificar por qué es interesante, y decidir qué técnica se le aplica. El objetivo no es solo que el código corra, sino que sepan defender cada decisión que tomaron sobre los datos: qué hicieron con valores faltantes, con posibles outliers, por qué eligieron esa técnica y no otra.

El trabajo se divide en tres partes. **La interpretación de cada parte se explica en detalle en el informe en PDF** (ver más abajo), no alcanza con código y gráficos sueltos.

1 Parte 1 — Elección del dataset y de la técnica

1.1 El dataset

Eliján un dataset real. Puede ser uno de los vistos en clase (EPH, o algún otro que hayamos usado en los ejemplos de Clase 1 a 5), o uno nuevo que el grupo consiga por su cuenta. Como referencia, algunas fuentes recomendadas:

- **Encuesta Permanente de Hogares (EPH), INDEC** — microdatos de hogares y de individuos, actualizados trimestralmente. <https://www.indec.gob.ar/indec/web/Insti-tucional-Indec-BasesDeDatos>
- **World Bank Open Data** — indicadores macro y de desarrollo para prácticamente todos los países del mundo, series largas. <https://data.worldbank.org/>
- **Kaggle Datasets** — gran variedad de datasets ya curados, muchos con notebooks de referencia. <https://www.kaggle.com/datasets>
- **Buenos Aires Data (GCBA)** — datos abiertos del Gobierno de la Ciudad de Buenos Aires (transporte, seguridad, presupuesto, ambiente, entre otros). <https://data.buenosaires.gob.ar/>

No están obligados a usar estas cuatro fuentes en particular: son puntos de partida razonables, no una lista cerrada. Si consiguen datos de otro lado (otro organismo público, un dataset armado por ustedes, una API), está bien, siempre que el dataset sea real y tenga volumen suficiente como para que el análisis tenga sentido.

- Justifiquen brevemente en el informe por qué eligieron ese dataset: qué pregunta les interesa responder con él.
- El dataset debe tener un tamaño razonable (no un puñado de filas) y variables suficientes como para permitir un análisis exploratorio genuino.

1.2 La técnica

Apliquen **al menos una** de las técnicas vistas en el módulo R:

- Regresión lineal, selección de variables y regularización (Ridge / LASSO / Elastic Net) — Clase 2.
- Series de tiempo: ARIMA / SARIMA, y ARIMAX si el dataset lo permite — Clase 3.
- Regresión logística y modelos lineales generalizados (GLM) — Clase 4.
- Datos de panel: efectos fijos, efectos aleatorios — Clase 5.

Importante: si quieren aplicar una técnica distinta a las cuatro listadas arriba (por ejemplo, algo que vieron en otra materia o que les interesa explorar), **es posible, pero primero tienen que consultarlo con el docente** antes de avanzar con el trabajo. No es necesario esperar a la clase de consulta para esto: pueden escribir en cualquier momento.

La elección de la técnica debe ser coherente con el dataset: no fuercen un ARIMA sobre datos que no son una serie de tiempo, ni una regresión logística sobre una variable que no es binaria. Parte del ejercicio es justamente esa decisión.

2 Parte 2 — Análisis exploratorio de datos (EDA)

Antes de aplicar cualquier técnica, hagan un análisis exploratorio serio. La consigna corta es: **"contar" qué tienen los datos**, en el sentido de poder explicarle a alguien que no los vio de qué se trata el dataset y qué particularidades tiene.

Como mínimo, esperamos que cubran:

- **Estructura general:** dimensiones del dataset, tipo de cada variable, período/cobertura temporal o geográfica si corresponde.
- **Valores faltantes:** ¿hay NAs? ¿en qué variables, en qué proporción? ¿el patrón de faltantes parece aleatorio o sistemático?
- **Distribuciones:** de las variables relevantes para el análisis — univariadas, y las relaciones bivariadas más importantes para la técnica elegida.
- **Valores atípicos o "algo raro":** si encuentran outliers, valores que no tienen sentido (edades negativas, códigos de "no sabe/no contesta" mezclados con datos numéricos, duplicados, etc.), **decidan explícitamente qué hacer con ellos y justifiquenlo** en el texto — no hace falta que la decisión sea "sacarlos"; puede ser dejarlos y explicar por qué, recodificarlos, etc. Lo que no puede pasar es que aparezcan en un gráfico y seguir de largo sin comentario.

Mucho gráfico, poco output crudo. Preferimos que el análisis se apoye en visualizaciones estratégicamente elegidas (con `ggplot2`) antes que en tablas de `summary()` pegadas sin curar. La elección de qué graficar y cómo es parte de lo que se evalúa, igual que en el módulo Python.

3 Parte 3 — Aplicación de la técnica e interpretación

- Apliquen la técnica elegida en la Parte 1, con el dataset ya explorado y, si corresponde, limpio o recodificado según lo que decidieron en la Parte 2.
- Muestren el ajuste del modelo con las salidas relevantes (coeficientes, medidas de ajuste, diagnósticos — lo que corresponda según la técnica).
- Incluyan al menos un gráfico que comunique el resultado principal del modelo (no solo el `summary()` en texto).
- Cierren con una interpretación sustantiva: ¿qué les dice el modelo sobre la pregunta que se plantearon en la Parte 1? ¿Qué limitaciones tiene el análisis?

El informe (PDF)

Además del código, cada grupo entrega un **informe en PDF, sin código**, que explique en prosa qué hicieron y por qué. La idea es que el informe se pueda leer de forma independiente del script: alguien que no vio el código tiene que poder entender el trabajo completo leyendo solo el PDF.

El informe debe incluir, para cada una de las tres partes:

- Una explicación detallada de qué se hizo (no un resumen de una línea): qué dataset usaron, qué variables, qué técnica aplicaron y por qué.
- Los gráficos relevantes, insertados en el informe (no solo mencionados), con su interpretación al lado.
- Las decisiones tomadas y su justificación: qué hicieron con los valores faltantes o atípicos que encontraron en el EDA, por qué eligieron esa técnica y no otra, cualquier supuesto que hayan tenido que asumir.
- La interpretación sustantiva de los resultados de cada parte.

No incluyan código ni output crudo de consola en el informe. El informe se evalúa como una pieza de comunicación en sí misma: lo que buscamos es que puedan explicar su propio trabajo con claridad a un lector que no va a mirar el script.

Requisitos de entrega

- Scripts de R ejecutables de principio a fin, con semilla fija (`set.seed()`) donde corresponda.
- **Informe en PDF**, sin código, con explicación detallada, gráficos e interpretación (ver sección anterior).
- **Repositorio en GitHub** con un `README.md` que explique brevemente: qué dataset usaron y de dónde salió, qué técnica aplicaron, y cómo correr el proyecto. El informe en PDF también debe estar en el repositorio.
- El proyecto debe poder correrse sin modificaciones por cualquier persona con acceso al repositorio (rutas relativas, sin dependencias de archivos locales fuera del repo).

Recuerden: se recomienda ir mostrando avances (el dataset elegido, primeros gráficos del EDA) durante las próximas clases o en la consulta virtual, para no descubrir problemas de último momento.